

Implementazione LM per l'analisi dell'insightfulness di recensioni

Paolo Costa, Mattia Corigliano

Dipartimento di Ingegneria Informatica, Modellistica, Elettronica e Sistemistica
Università della Calabria, Arcavacata, Rende (CS)

18 giugno 2026

Obiettivo del Progetto

Scopo principale: Implementare un'architettura in grado di valutare l'**insightfulness** di una recensione testuale, assegnando uno score (0-100).

Cos'è l'Insightfulness?

- **Basso livello:** Recensioni superficiali, generiche o puramente emotive (es. *"Tutto perfetto!"*).
- **Alto livello:** Testi ricchi di informazioni specifiche, contestualizzate, verificabili (scenari d'uso, dettagli tecnici, pros/cons concreti).

Motivazione: Fornire all'utente finale un indicatore concreto dell'utilità decisionale di una recensione, filtrando i contenuti scarsamente informativi.

Definizione delle Task dell'Architettura

Task Principale (Modello Fine-Tuned):

- Predizione dello score di *insightfulness* tramite l'ottimizzazione di teste ausiliarie su un Language Model di base.
- Apprendimento di rappresentazioni semantiche sensibili a fattualità e lessicalità.

Task Secondarie (LLM Locali/Cloud e RAG):

- **Analisi Grammaticale:** Individuazione di errori oggettivi, ortografici e verbali con indicazione esatta degli indici nel testo.
- **Compliance Checker:** Verifica delle linee guida della piattaforma tramite Retrieval-Augmented Generation (RAG).
- **Feedback Generativo:** Suggerimenti mirati per migliorare la qualità del testo.

Implementazione dell'Architettura

Sistema suddiviso in **Frontend** (React) e **Backend** (API, Database, Modelli ML).

Core Neurale: DeBERTaV3-Large

- *Backbone*: Transformer da 24 layer ($\sim 304\text{M}$ parametri) per Natural Language Understanding.
- *Attention Pooling*: Calcolo della rappresentazione sull'intera sequenza.

Architettura a Teste Ausiliarie (Training Multi-task):

- ➊ **Regression Head (Main)**: Score 0-100 (addestrata tramite Knowledge Distillation).
- ➋ **Factuality Head**: Stima la densità informativa (segnali offline).
- ➌ **Lexical Head**: Predice feature lessicali (rapporto sostantivi, verbi, entità) regolarizzando lo spazio latente.

In inferenza, il sistema utilizza unicamente il testo grezzo e la Regression Head, rendendolo estremamente efficiente.

Analisi del Dataset: Composizione e Preprocessing

Integrazione di tre fonti eterogenee per garantire variabilità semantica:

- **BnB:** ~346.000 recensioni
- **Amazon:** ~133.000 recensioni (suddivise per categorie merceologiche)
- **Restaurant:** ~35.000 recensioni
- **Totale:** ~514.777 campioni

Labeling e Preprocessing:

- **Teacher Model:** gemma3:27B utilizzato per assegnare lo score target di insightfulness (Knowledge Distillation).
- **Estrazione Offline (spaCy):** Calcolo di *Noun/Verb/Adj ratio*, *Entity density* e un punteggio algoritmico di Fattualità.

Analisi del Dataset: Distribuzioni e Caratteristiche

Lunghezza e Score Globale

- Maggior parte delle recensioni sotto le 150 parole (ideale per il contesto del Transformer).
- Distribuzione degli score multimodale, con picchi a valori bassi (15-35) e medio-alti (63-70).

Dipendenza dal Dominio

- **Amazon & Restaurant:** Mediane più basse (~ 28 - 31), maggior presenza di giudizi stringati.
- **BnB:** Mediana significativamente più alta (~ 62), recensioni intrinsecamente più descrittive e contestualizzate.




Figura 1: Distribuzione globale degli score di insightfulness.

Necessità di inserire la Geometric Bound Loss nel training per gestire i bias di categoria.

Protocollo di Addestramento

Loss Composita:

$$L = \alpha L_{distill} + \beta L_{factuality} + \gamma L_{bound} + \delta L_{lexical} + \lambda L_{rank}$$

- **Distillation Loss** ($\alpha = 0.5$): MSE verso lo score del Teacher.
- **Geometric Bound** ($\gamma = 0.2$): Allinea l'embedding proiettandolo sull'asse *worst-best* della rispettiva categoria.
- **Margin Ranking, Factuality e Lexical**: Segnali di regolarizzazione.


Configurazione Ottimizzazione:

- **Optimizer**: AdamW con Gradient Accumulation.
- **Scheduler**: *Cosine Annealing with Warm Restarts* per esplorare la superficie della loss ed evitare minimi locali.

Analisi del Training: Curve di Loss

Andamento del Training (117 Epoche):

- **Fase iniziale (PEFT):** Apprendimento lento delle teste ausiliarie mantenendo l'encoder congelato. Alta presenza di oscillazioni nella validation.
- **Crollo della Loss (Epoca 93):** Passaggio al **full fine-tuning**. Stabilizzazione improvvisa del modello.



Analisi delle componenti:

- La *Bound Loss* ha subito un calo considerevole: il modello ha imparato ad allineare correttamente le rappresentazioni latenti.
- Miglioramento significativo della *Factuality Loss*, indicando una maggiore capacità di quantificare i contenuti oggettivi.




Figura 2: Curve di loss per training e validation.

Analisi del Training: Metriche di Validazione

Risultati pratici sul compito di scoring:

- **Pearson Coefficient:** Impennata quasi immediata, a dimostrazione che DeBERTa riesce rapidamente a distinguere le recensioni agli estremi (molto utili vs inutili). Raggiunge un picco di **0.93** dopo il full fine-tuning.
- **Mean Absolute Error (MAE):** Scende da 0.095 a un minimo di **0.058** (deviazione media del 5.8% sulla scala dello score).

La combinazione di Geometric Bound Loss e scheduling del learning rate ha permesso a DeBERTa di ricostruire una geometria latente coerente con l'insightfulness.




Figura 3: Evoluzione delle metriche di validazione nel corso delle epoche.

Confronto con Modelli Cloud (Inference)

Il modello **DeBERTa Fine-Tuned** è stato confrontato con LLM ad altissima capacità (**Gemini 3.1 Flash** e **GPT-OSS 120b**):

- **Efficienza:** Tempo di inferenza nettamente inferiore rispetto a qualsiasi API cloud grazie all'architettura encoder.
- **Correlazione:** Elevata (0.82) con i modelli locali (Ollama), ma moderata (0.62) rispetto a Gemini.
- **Tendenza Conservativa:** Il modello concentra gli score nel range 20-40, ereditando distribuzioni sbilanciate dal *Teacher*. I modelli cloud premiano più facilmente con punteggi alti.




Figura 4: DeBERTa vs Gemini vs GPT-oss:120B

Conclusioni sull'Architettura Globale

Task Principale (Scoring):

- L'approccio ibrido (teste ausiliarie + Knowledge Distillation) ha generato un modello end-to-end rapido, coerente con il Teacher e computazionalmente leggero a runtime.

Task Secondarie (RAG e LLM Locali):

- **Successi:** La RAG deterministica applica ottimamente il check euristico e normativo sulle policy delle piattaforme.
- **Criticità LLM:** Gemma3/Gemma4 faticano nell'individuazione esatta degli indici di testo per la correzione grammaticale (problemi con gli accenti, allucinazioni e latenza elevata).
- **Soluzione Futura:** Sostituzione dell'LLM generico con un modello Task-Specific (es. *grammar-correction-model*).

Alternative di Sviluppo e Sviluppi Futuri

Il limite principale risiede nel bias conservativo ereditato dal Teacher Model. Un'alternativa metodologica è il **RLHF (Reinforcement Learning from Human Feedback)**:

- ❶ Raccolta di annotazioni umane basate su **confronti relativi** (Recensione A > Recensione B) piuttosto che su valori assoluti 0-100.
- ❷ Addestramento di un **Reward Model** su queste preferenze.
- ❸ Calibrazione del modello di scoring sulle percezioni umane reali di utilità.

Prossimi step: Pur mantenendo la Knowledge Distillation per questioni di costi e scalabilità, l'utilizzo di un Teacher più avanzato (SOTA) in fase di label-generation migliorerà nettamente l'accuratezza finale del sistema.